

Emma Crusiot

PROJET PERSONNEL : ANALYSE EN GÉNÉTIQUE ET BIO-INFORMATIQUE

Table des matières

Introduction générale.....	3
Exercice 1 : Le motif Tabby chez le chat.....	4
1) Introduction.....	4
2) Méthodes.....	4
3) Conclusion.....	7
Exercice 2 : Le gène MYH7 chez les Mammifères.....	8
1) Introduction.....	8
2) Méthodes.....	8
3) Conclusion.....	11
Conclusion générale.....	12
Bibliographie.....	13

Introduction générale :

L'objectif de ce projet personnel est de démontrer mes connaissances en génétique, statistiques et bio-informatique ainsi que ma capacité à apprendre de manière autonome des notions de programmation sur R. Certains modèles peuvent être simplifiés pour se concentrer avant tout sur mes compétences en programmation.

Pour commencer à approfondir mes connaissances en programmation, j'ai utilisé le livre *Population Genetics with R : An Introduction for Life Scientists* de Áki Jarl Láruson et Floyd A. Reed. Cette lecture m'a permis de consolider des notions que j'avais vues en génétique pendant ma formation et de me familiariser avec certains aspects de R dont l'utilisation des boucles (for, while et if), la simulation de populations et l'utilisation de l'algorithme d'espérance-maximisation. Ce livre a directement inspiré la conception de l'exercice 1.

Puis, j'ai souhaité approfondir mes connaissances en bio-informatique tout en continuant le développement de mes compétences en programmation. Pour ce faire, j'ai lu l'ouvrage *R programming for Bioinformatics* de Gentleman, qui m'a permis de mieux comprendre le fonctionnement interne de R, dont les indices de position. J'ai également lu *Introduction to Bioinformatics with R : A Practical Guide for Biologists* de Edward Curry pour les connaissances en bio-informatique.

Ces livres ont inspiré l'exercice 2 de ce projet et m'ont conduit à utiliser Bioconductor, dont le package rBLAST, ainsi qu'à mieux comprendre le fonctionnement des bases de données sur NCBI.

La réalisation de ce projet m'a permis de renforcer ma compréhension de la programmation, de découvrir des outils de bio-informatique. De plus, cela représentait une opportunité pour moi d'expérimenter les notions vues pendant mes lectures et d'adopter une démarche d'apprentissage basée sur les essais, les erreurs et la correction progressive.

Enfin, ce projet a été une expérience très motivante, parce qu'il m'a encouragé à chercher à mieux comprendre la programmation et les outils en bio-informatique et à m'adapter malgré les difficultés rencontrées. Ce choix m'a conforté dans mon souhait de poursuivre dans le domaine de la bio-informatique.

Exercice 1 : Le motif Tabby chez le chat

1) Introduction :

Les chats présentent une grande variété de pelage, tant en terme de couleurs que de motifs. Ce projet se concentre sur les motifs dits « Tabby », qui comprennent : Mackerel tabby, Blotched tabby, Spotted tabby et Ticked tabby.

Ces motifs illustrent la complexité génétique du pelage chez le chat. Des études plus récentes (Eizirik et al. (2010)) ont montré qu'au moins 3 loci sont impliqués :

- Le gène LVRN (ou Tabby) gouvernant le type de motif avec un allèle TaM dominant (Mackerel) et un allèle Tab récessif (Blotched).
- Le gène Ticked gouvernant l'absence ou la présence du motif avec un allèle TiA dominant sur l'allèle Ti+.
- Un ou plusieurs gènes inconnu(s) gouvernant le motif Spotted.

Pour cet exercice, nous simplifions le modèle en ne considérant que le gène LVRN, qui est biallélique et indépendant des autres loci. Nous l'étudions à partir d'une population de chats sauvages décrite par Kaelin et al. (2012).

L'objectif est de calculer les fréquences alléliques suivant le principe de Hardy-Weinberg, ensuite d'estimer les fréquences alléliques à l'aide de l'algorithme d'espérance-maximisation (EM) et enfin de comparer les fréquences alléliques obtenues pour chaque méthode.

2) Méthodes :

Description des données :

La population de chats sauvages étudiée comprend 49 individus, dont 33 Mackerel tabby [TaM] et 16 Blotched tabby [Tab].

Comme dit précédemment, le gène LVRN étant biallélique, il y a 3 génotypes possibles : (TaM//TaM), (TaM//Tab) et (Tab//Tab).

De plus, l'allèle TaM est dominant sur l'allèle Tab. Ainsi pour le phénotype dominant [TaM], nous ne pouvons pas distinguer les individus homozygotes (TaM//TaM) des individus hétérozygotes (TaM//Tab).

Ces deux génotypes sont considérés comme étant des génotypes latents. Cela signifie que nous ne pouvons les observer à partir du phénotype.

Calcul des fréquences alléliques avec le principe de Hardy-Weinberg :

La structure génétique du gène LVRN sera noté ainsi :

- $f[\text{TaM}]$ et $f[\text{Tab}]$: les fréquences des phénotypes [TaM] et [Tab]
- $f(\text{TaM//TaM})$, $f(\text{TaM//Tab})$ et $f(\text{Tab//Tab})$: les fréquences des génotypes (TaM//TaM), (TaM//Tab) et (Tab//Tab).
- $f(\text{TaM})$ et $f(\text{Tab})$: les fréquences des allèles (TaM) et (Tab).

De plus, de manière arbitraire, $f(\text{TaM})$ sera noté q et $f(\text{Tab})$ sera noté p .

A partir de ce que nous savons sur le gène LVRN et connaissant le nombre d'individus par phénotype, nous pouvons calculer les fréquences phénotypiques.

Nous savons que :

$$f[\text{TaM}] = f(\text{TaM//TaM}) + f(\text{TaM//Tab})$$

$$- f[\text{Tab}] = f(\text{Tab} // \text{Tab})$$

Donc,

```
# Taille pour chaque phénotype et taille totale de la population.
TaM <- 33
Tab <- 16
N <- TaM+Tab      # 49

# Calcul des fréquences phénotypes.
fTaM <- TaM/N      # 0.6735
fTab <- Tab/N       # 0.3265

# Affichage des résultats.
fphenotypes <- c(fTaM = fTaM, fTab = fTab)
fphenotypes
```

Pour estimer le reste de la structure génétique (malgré les génotypes latents), nous supposons que la population fonctionne comme une population idéale à l'équilibre de Hardy-Weinberg.

Sous le principe de Hardy-Weinberg :

$$- f[\text{TaM}] = f(\text{TaM} // \text{TaM}) + f(\text{TaM} // \text{Tab}) = q^2 + (2xpqx)$$

$$- f[\text{Tab}] = f(\text{Tab} // \text{Tab}) = p^2 \Leftrightarrow \sqrt{f(\text{Tab} // \text{Tab})} = p$$

Nous pouvons calculer p. Donc,

```
# Calcul de la fréquence allélique p.
p <- sqrt(Tab/N)    # 0.5714
p
```

Pour avoir q, nous savons que la somme des fréquences alléliques est égale à 1.

Donc, $p+q = 1 \Leftrightarrow q = 1-p$:

```
# Calcul de la fréquence allélique q.
q <- 1-p            # 0.4286
q
```

Maintenant avec q, nous pouvons calculer ce qui nous manque. Nous savons que :

$$f(\text{TaM} // \text{TaM}) = q^2 \text{ et } f(\text{TaM} // \text{Tab}) = 2xpqx$$

Donc,

```
# Calcul des fréquences génotypiques.
fTaMTaM <- q^2      # 0.1837
fTaMTab <- 2*p*q    # 0.4898

fgenotypes <- c(fTaMTaM = fTaMTaM, fTaMTab = fTaMTab, fTabTab = p^2 )
fgenotypes
```

Estimation des fréquences alléliques avec l'algorithme EM :

L'algorithme EM permet d'estimer des paramètres pour maximiser la probabilité des données observées lorsque certaines données sont non observables. Dans notre cas, en sachant que le nombre d'individus des génotypes latents nous est inconnues, l'EM va alors nous permettre d'estimer les fréquences alléliques les plus probables à partir de nos données.

L'algorithme fonctionne en deux phases :

- phase E : estimations des données inconnues, c'est-à-dire les génotypes latents, à partir des fréquences alléliques calculées à l'itération précédente.
- phase M : mise à jour des fréquences alléliques à partir de ces estimations.

En répétant ces étapes, nous maximisons la vraisemblance. Nous obtenons ainsi les fréquences alléliques rendant les phénotypes observés (33 Mackerel et 16 Blotched) les plus probables.

Maintenant, nous pouvons utiliser R pour coder l'algorithme EM et ainsi estimer les fréquences alléliques.

Voici le code utilisé :

```
TaM <- 33
Tab <- 16

EM <- function(p, q){

  N <- TaM+Tab
  # Calcul des fréquences alléliques.
  p <- sqrt(Tab/N)
  q <- 1-p

  # Création de variables pour les anciennes itérations de nos fréquences alléliques.
  p0 <- 0
  q0 <- 0
  counter <- 0 # Cela va nous permettre de compter le nombre d'itération.

  # Initialisation de l'algorithme avec la fonction while.
  while(!isTRUE(all.equal(p0,p, tolerance = 1e-12)) &&
        !isTRUE(all.equal(q0,q, tolerance = 1e-12))){
    # Sauvegarde des valeurs de l'ancienne itération.
    p0 <- p
    q0 <- q

    # Phase E :
    fMM <- TaM*(q0^2/((q0^2)+2*(q0*p0)))
    fMb <- TaM*(2*(q0*p0)/((q0^2)+2*(q0*p0)))
    fbb <- Tab

    # Phase M :
    q <- ((2*fMM)+fMb)/(2*N)
```

```

p <- ((2*fbb)+fMb)/(2*N)

counter <- counter + 1
}
#Pour retourner, les valeurs après convergence et le nombre d'itérations.
return(c(paste("p =", round(p,4), ", q =", round(q,4), "Itération =",
counter)))
}

# Exécution de l'algorithme.
EM(p, q)

```

Après exécution de l'algorithme, nous obtenons ces valeurs :

```

> EM(p, q)
[1] "p = 0.5714 , q = 0.4286 Itération = 1"

```

3) Conclusion :

Nous remarquons que les fréquences alléliques obtenues par les deux méthodes sont identiques. L'EM a convergé en une seule itération, car les fréquences initiales sont déjà proches du maximum de vraisemblance.

Bien que dans notre cas, l'EM ne fournisse pas d'informations supplémentaire, il reste tout de même un outil puissant pour estimer des fréquences alléliques dans des populations plus complexes.

Bien évidemment, le modèle initial a volontairement été simplifié pour se concentrer sur un seul gène biallélique et ne reflète pas la complexité génétique du motif Tabby chez le chat.

Exercice 2 : Le gène MYH7 chez les Mammifères

1) Introduction :

Le gène MYH7 code pour la protéine chaîne lourde de la bêta-myosine. Cette protéine joue un rôle essentiel dans la contraction du muscle cardiaque. De nombreuses études ont démontré que des mutations de ce gène sont responsables de certaines cardiomyopathies héréditaires.

Ces études soulignent l'importance physiologique de ce gène, impliquant une plus grande conservation au sein des mammifères.

L'objectif est de comparer les séquences nucléotides du gène chez différents mammifères avec BLAST puis de visualiser les regroupements possibles en fonction du degré de similarité à l'aide d'un clustering hiérarchique.

2) Méthodes :

Description des données :

Le gène étudié est celui du gène MYH7. Pour l'analyse BLAST, nous utilisons arbitrairement la séquence chez le chat comme référence (= query).

Les autres séquences, qui seront comparées avec le chat, proviennent de 10 espèces de mammifères. Ce choix va nous permettre de couvrir les principaux groupes de mammifère et ainsi observer le regroupement s'il se fait. Les autres espèces sont : Humain/Chimpanzé, Vache/Cochon/Cheval, Rat/Souris, Chien, Elephant et Dauphin.

Utilisation du package rBLAST :

Un BLAST est un outil permettant de comparer des séquences de nucléotides ou d'acides aminés afin d'identifier des régions de similarité puis de réaliser des alignements entre des séquences homologues.

Dans notre cas, nous comparons des séquences de nucléotides chez 11 espèces de mammifères, afin d'évaluer le degré de similarité du gène entre notre séquence de référence et les autres espèces.

Nous pouvons faire un BLAST à partir du site du NCBI. Toutefois, dans le projet de Bioconductor nous pouvons trouver un package sur R nommé « rBLAST ». Ce dernier permet d'intégrer directement les analyses au sein de R et ainsi faciliter l'automatisation et surtout la reproductibilité du travail. Donc, nous allons privilégier l'utilisation de ce package.

- Téléchargement des fichiers FASTA

Avant de réaliser notre BLAST, il faut télécharger des fichiers au format FASTA de chaque séquence depuis NCBI. L'identifiant des séquences nous permet de savoir si la séquence a été curé dans RefSeq (« NM ») ou si la séquence a été automatiquement prédite depuis le génome (« XM »).

Pour une raison de qualité des données, les séquences annotées « NM » ont été privilégiées dans la mesure du possible. Dans le cas contraire, les séquences annotées « XM » sont acceptées et utilisées.

Le téléchargement peut se faire directement sur R en utilisant la forme d'url suivante : https://eutils.ncbi.nlm.nih.gov/entrez/eutils/efetch.fcgi?db=nucleotide&id=<uid_list>&rettype=fasta&retmode=text

Il nous suffira de simplement remplacer l'identifiant NCBI pour chaque séquence pour l'id.
Nous pouvons télécharger sur R tous les fichiers en séparant notre séquence de référence du reste.

```
# Pour le téléchargement, nous utilisons la commande « download.file ».
download.file('https://eutils.ncbi.nlm.nih.gov/entrez/eutils/efetch.fcgi?
db=nucleotide&id=XM_006932746.5&rettype=fasta&retmode=text',
'MYH7_chat.fasta')

# Nous allons lire le fichier FASTA et le mettre sous le nom « query ».
query <- readDNASTringSet('MYH7_chat.fasta')

# Pour le reste, nous allons automatiser.
# Ici, nous définissons l'identifiant NCBI de toutes les séquences.
sujets_num <-
c('NM_000257.4','XM_014733468.3','NM_001113711.1','NM_080728.3','NM_017240.2
','NM_213855.2','NM_174727.1','XM_016925890.4','XM_064292317.1','XM_00744956
2.1')

# Ici, nous définissons le nom des espèces correspondantes.
id <-
c('Humain','Cheval','Chien','Souris','Rat','Cochon','Vache','Chimpanze','Ele
phant','Dauphin')

# Ici, nous allons créer le nom de chaque fichier FASTA.
sujets_id <- paste0('MYH7_', id, '.fasta')

# Nous pouvons télécharger de manière automatique.
for (i in 1:10){
# Utiliser paste0 nous permet de pouvoir rajouter l'identifiant des
séquences et avoir le lien final pour toutes les séquences.
download.file(paste0('https://eutils.ncbi.nlm.nih.gov/entrez/eutils/
efetch.fcgi?db=nucleotide&id=',sujets_num[i],&rettype=fasta&retmode=text')
, sujets_id[i])
}

# Nous pouvons lire les fichiers et les rassembler puis s'assurer que ça a
bien fonctionné.
sujets_files <- readDNASTringSet(sujets_id)
print(sujets_files)
```

- Analyse BLAST :

Pour exécuter l'analyse sur R, nous allons rassembler tous nos fichiers lus dans un objet pour créer un fichier au même format contenant tout. Cela va nous permettre de créer une base de données locale pour exécuter correctement notre analyse BLAST.

```
# Création de l'objet avec tous nos fichiers.
all_files <- c(sujets_files,query)

# Création d'un nouveau fichier combinant tout.
```

```
writeXStringSet(all_files, filepath = 'sujets_seq')

# Création de la base de données locale.
database <- makeblastdb('sujets_seq', dbtype='nucl')

# Nous pouvons exécuter BLAST.
blast <- blast(db = 'sujets_seq', type = 'blastn')
results <- predict(blast, query)
print(results)
```

Après analyse, nous obtenons les résultats suivants :

	qseqid	sseqid	pident	length	mismatch	gapopen	qstart	qend	sstart	send	eval	bitscore
1	XM_006932746.5	XM_006932746.5	100.000	6097	0	0	1	6097	1	6097	0	11260
2	XM_006932746.5	XM_014733468.3	94.061	6095	356	5	1	6093	115	6205	0	9245
3	XM_006932746.5	NM_001113711.1	95.368	5808	269	0	171	5978	1	5808	0	9236
4	XM_006932746.5	NM_213855.2	94.018	6035	353	6	62	6093	1	6030	0	9138
5	XM_006932746.5	XM_007449562.1	93.831	5949	366	1	145	6093	16	5963	0	8951
6	XM_006932746.5	NM_174727.1	93.810	5929	362	4	166	6093	4	5928	0	8911
7	XM_006932746.5	XM_016925890.4	93.241	6036	397	8	64	6095	9	6037	0	8876
8	XM_006932746.5	NM_000257.4	93.153	6032	402	8	68	6095	1	6025	0	8841
9	XM_006932746.5	XM_064292317.1	92.466	5933	437	4	167	6092	12	5941	0	8471
10	XM_006932746.5	NM_017240.2	92.195	5817	452	2	163	5978	1	5816	0	8226
11	XM_006932746.5	NM_080728.3	91.859	5859	470	7	129	5983	100	5955	0	8170

Tableau contenant tous les résultats obtenus après analyse BLAST sur R, donnant : le pourcentage d'identité (pident)

Clustering :

Le clustering est une méthode d'analyse permettant de regrouper un ensemble d'objets en plusieurs sous-ensembles homogènes sur la base de leur similarité. Il existe plusieurs types de méthode de clustering.

Dans ce projet, nous avons choisi d'utiliser un clustering dit « hiérarchique ». Ce choix est motivé par le fait que nous pouvons définir une mesure de similarité, à partir de laquelle une distance est calculée. Le paramètre utilisé sera le pourcentage d'identité (%identity) obtenu à partir des résultats du BLAST. Ce paramètre représente la proportion de nucléotides identiques entre la séquence de référence et les autres séquences et est alors un indicateur de la similarité entre les séquences.

De plus, avec un clustering hiérarchique, nous pouvons faire un dendrogramme pour visualiser les relations entre la séquence de référence et les autres séquences, et ainsi faciliter l'interprétation.

Voici le code utilisé pour faire le clustering et le dendrogramme :


```
# Création d'un dataframe avec les identifiants et le paramètre choisi.
new_results <- data.frame(results$sseqid, results$pident, row.names =
c("Chat", "Cheval", "Chien", "Cochon", "Dauphin", "Vache", "Chimpanzé", "Humain", "Elephant", "Rat", "Souris"))

# Nous pouvons calculer la matrice des distances et réaliser un clustering hiérarchique.
hclust(dist(new_results))

# Enfin, nous pouvons faire le dendrogramme avec plot.
plot(hclust(dist(new_results)),
      hang = -1,
```

```
main = "Dendrogramme illustrant la similarité des séquences du gène MYH7 entre le chat et différents mammifères")
```

Le dendrogramme obtenu est présenté ci-dessous :



Nous observons sur le dendrogramme des clusters bien distincts. Nous avons un regroupement de : le Chien, l'Homme et le Chimpanzé, la Souris avec le Rat et l'Elephant, le Cochon et le Cheval, le Dauphin et la Vache.

3) Conclusion :

Les regroupements observés sont cohérents avec la phylogénie au niveau des grands clades avec les Primates, les Rongeurs et les Carnivores.

Le regroupement du Dauphin avec les Ongulés reste cohérent. Les Cétacés et les Ruminants forment le clade des Cetruminantia.

Cependant, si nous observons plus finement, nous remarquons des incohérences avec la phylogénie. En effet, nous avons le Cheval qui est regroupé avec le Cochon alors que ce dernier devrait être regroupé avec la Vache car ce sont des Artiodactyles. Donc le cheval aurait dû former un autre cluster pour les Périssodactyles. De plus, l'Elephant est regroupé avec le Rat. Ce point est incohérent même en se concentrant sur une plus grande échelle car les Rongeurs et Proboscidea n'appartiennent pas au même super-ordre.

Ces incohérences sont normales et s'expliquent par la méthode de comparaison.

Tout d'abord, il faut rappeler que nous comparons toutes les espèces par rapport au Chat, ainsi les clusters reflètent les similarités relatives et non la phylogénie absolue entre espèces. Il serait intéressant de voir les clusters que nous obtiendrions après avoir comparé toutes les espèces entre elles.

Enfin, l'analyse repose sur un seul gène. Un gène ne contient pas toutes les informations nécessaires pour observer les relations phylogénétiques. L'une des raisons est l'hétérogénéité de l'horloge moléculaire entre les groupes de mammifères. Ces limites soulignent l'importance d'utiliser plusieurs gènes, ainsi que différentes approches pour pouvoir observer les regroupements les plus fidèles à la réalité.

Pour autant, les pourcentages d'identité observés (au-dessus de 90%) confirment la conservation du gène MYH7 chez les mammifères, en lien avec son rôle essentiel dans la contraction du cœur.

Conclusion générale :

La réalisation de ce projet m'a permis de passer de la théorie à la pratique, et ainsi d'approfondir ma compréhension des outils tels que l'algorithme EM ou l'utilisation de packages Bioconductor, notamment rBLAST. Ce projet a également renforcé ma capacité d'apprentissage en autonomie et mon esprit critique.

Bien que le choix des exercices ait été motivé par curiosité personnelle, ils m'ont permis de découvrir des concepts en lien avec la génomique clinique. Dans le premier exercice, j'ai été confrontée à l'analyse de données incomplètes, en raison de la présence de génotypes latents. Cela m'a montré qu'une approche probabiliste est possible même en cas d'incertitude et permet de continuer l'analyse sans s'arrêter trop tôt.

Pour le deuxième exercice, j'ai pu mieux observer les notions de conservation des gènes entre espèces et le lien avec la fonction biologique. Ces notions m'étaient connues grâce à mes cours en « Biologie évolutive » mais je n'avais pas eu l'occasion de les explorer concrètement. J'ai ainsi pu observer que des gènes avec des fonctions essentielles, comme MYH7, sont fortement conservés, afin de garder la fonction biologique. Les mutations sont donc susceptibles d'avoir un impact fonctionnel. Ces notions sont des éléments à prendre en compte dans l'interprétation des variants.

Au final, ce projet m'a permis de travailler autour de notions dans le domaine de la génomique clinique en plus de la bio-informatique. Je reste néanmoins consciente des compétences tant techniques que cliniques nécessaires pour cette voie. Concernant les compétences techniques, le master Bioinformatique et Biologie des Systèmes me permettrait d'acquérir ces compétences telles que l'annotation de variants, la compréhension des pipelines ainsi que celle des réseaux biologiques. En plus du master et dans la continuité de ce travail autonome, je développe des compétences sur Linux. Pour les compétences cliniques, je prévois de me familiariser avec les bases de données comme OMIM et ClinVar, afin de comprendre l'interprétation des variants.

Bibliographie :

- Eizirik, E., David, V. A., Buckley-Beason, V., Roelke, M. E., Schaffer, A. A., Hannah, S. S., Narfström, K., O'Brien, S. J., & Menotti-Raymond, M. (2010). Defining and mapping mammalian coat pattern genes: multiple genomic regions implicated in domestic cat stripes and spots. *Genetics*, 184(1), 267–275. <https://doi.org/10.1534/genetics.109.109629>
- Kaelin, C., & Barsh, G. (2010). Tabby pattern genetics - a whole new breed of cat. *Pigment cell & melanoma research*, 23(4), 514–516. <https://doi.org/10.1111/j.1755-148X.2010.00723.x>
- Kaelin, C. B., Xu, X., Hong, L. Z., David, V. A., McGowan, K. A., Schmidt-Küntzel, A., Roelke, M. E., Pino, J., Pontius, J., Cooper, G. M., Manuel, H., Swanson, W. F., Marker, L., Harper, C. K., van Dyk, A., Yue, B., Mullikin, J. C., Warren, W. C., Eizirik, E., Kos, L., ... Menotti-Raymond, M. (2012). Specifying and sustaining pigmentation patterns in domestic and wild cats. *Science (New York, N.Y.)*, 337(6101), 1536–1541. <https://doi.org/10.1126/science.1220893>
- Hahsler M, Nagar A (2024). “rBLAST: R Interface for the Basic Local Alignment Search Tool.” Bioconductor version: Release (3.19). doi:10.18129/B9.bioc.rBLAST <https://doi.org/10.18129/B9.bioc.rBLAST>, R package version 0.99.4.
- <https://github.com/mhahsler/rBLAST/blob/devel/vignettes/blast.Rmd>
- https://www.ncbi.nlm.nih.gov/books/NBK25500/#chapter1.Uploading_UIDs_to_Entrez
- https://www.ncbi.nlm.nih.gov/books/NBK21091/tablech18.T.refseq_accession_numbers_and_mole/?report=objectonly
- Gao, Y., Peng, L., & Zhao, C. (2024). MYH7 in cardiomyopathy and skeletal muscle myopathy. *Molecular and cellular biochemistry*, 479(2), 393–417. <https://doi.org/10.1007/s11010-023-04735-x>
- Tanjore, R., Rangaraju, A., Vadapalli, S., Remersu, S., Narsimhan, C., & Nallari, P. (2010). Genetic variations of β -MYH7 in hypertrophic cardiomyopathy and dilated cardiomyopathy. *Indian journal of human genetics*, 16(2), 67–71. <https://doi.org/10.4103/0971-6866.69348>
- Yousaf, M., Khan, W. A., Shahzad, K., Khan, H. N., Ali, B., Hussain, M., Awan, F. R., Mustafa, H., & Sheikh, F. N. (2022). Genetic Association of Beta-Myosin Heavy-Chain Gene (MYH7) with Cardiac Dysfunction. *Genes*, 13(9), 1554. <https://doi.org/10.3390/genes13091554>